

Universidad Mariano Gálvez de Guatemala

Facultad de Ingeniería en Sistemas

CURSO: Inteligencia Artificial

CATEDRATICO: Ing. Carmelo Estuardo Mayén Monterroso

SEMESTRE: Noveno

CONTENIDO: Manual Técnico

ALUMNOS: Guillermo José Gómez Aguilera – Scrum Master

Wilson Eduardo Hernandez López – Desarrollador

Bagner Francisco Ojeda Esquite – Desarrollador

Amner Alberto Pérez Marroquin – Documentación

Teddy Leonardo Hernandez Pérez – Documentación

CARNÉ: 1790-22-16429

1790-22-7315

1790-18-25212

1790-22-7230

1790-22-2563

Chiquimula, 25 de julio 2026

ÍNDICE

1. Introducción.....	1
2. Objetivos	2
3. Descripción General del Sistema.....	2
4. Arquitectura del Sistema.....	3
5. Tecnologías Utilizadas	3
6. Instalación y Configuración	4
7. Estructura del Proyecto.....	5
8. Funcionamiento del Sistema	6
9. Componentes Técnicos.....	7
10. Modelo de Inteligencia Artificial.....	7
11. Flujo de Procesamiento.....	8
12. Estructura de Datos.....	8
13. Interfaz del Sistema.....	9
14. Testing y Validación	9
15. Seguridad y Privacidad.....	9
16. Troubleshooting.....	10
17. Beneficios del Sistema.....	10 - 11
18. Casos de Uso.....	11
19. Conclusiones.....	12
20. Referencias.....	13
21. Anexos.....	14 - 16

1. INTRODUCCIÓN

Actualmente muchas empresas e instituciones aún realizan procesos manuales para clasificar documentos y extraer información importante, lo cual provoca pérdida de tiempo, errores humanos y dificultad en la organización de datos.

El presente proyecto consiste en el desarrollo de un sistema inteligente basado en OCR (Reconocimiento Óptico de Caracteres) e Inteligencia Artificial capaz de automatizar la extracción y clasificación de documentos.

El sistema permite procesar imágenes y archivos PDF para identificar automáticamente documentos como facturas, contratos, recibos, constancias y documentos de identidad, extrayendo información relevante como NIT, DPI, UUID SAT, fechas y montos.

Además, el sistema fue adaptado específicamente al contexto guatemalteco, permitiendo reconocer formatos y estructuras utilizadas en documentos fiscales y administrativos de Guatemala.

2. OBJETIVOS

Objetivo General

Desarrollar un sistema inteligente basado en OCR e Inteligencia Artificial capaz de clasificar y extraer información automáticamente desde documentos digitales.

Objetivos Específicos

- Implementar OCR utilizando Tesseract OCR.
- Automatizar la clasificación documental mediante Machine Learning.
- Extraer datos importantes utilizando expresiones regulares.
- Procesar imágenes y PDFs multipágina.
- Generar resultados estructurados en formato JSON.
- Implementar una interfaz moderna utilizando Streamlit.
- Optimizar el procesamiento documental reduciendo errores humanos.

3. DESCRIPCIÓN GENERAL DEL SISTEMA

El sistema recibe documentos en formato imagen o PDF y realiza automáticamente los siguientes procesos:

1. Extracción de texto mediante OCR.
2. Limpieza y normalización del texto.
3. Extracción de datos importantes.
4. Clasificación documental mediante IA.
5. Generación de resultados estructurados.

El resultado final es mostrado en una interfaz gráfica y puede exportarse en formato JSON.

4. ARQUITECTURA DEL SISTEMA

Arquitectura General

El sistema está compuesto por los siguientes módulos:

- OCR Processor
- Data Extractor
- Contextual Extractor
- Semantic Analyzer
- Document Classifier
- OCR Pipeline
- Streamlit UI

Flujo General

Entrada → OCR → Extracción → Clasificación → JSON → Interfaz

5. TECNOLOGÍAS UTILIZADAS

Tecnología	Función
------------	---------

Python 3.10+	Lenguaje principal
--------------	--------------------

Tesseract OCR	Reconocimiento de texto
---------------	-------------------------

pytesseract	Integración OCR
-------------	-----------------

scikit-learn	Machine Learning
--------------	------------------

OpenCV	Procesamiento de imágenes
--------	---------------------------

PIL	Manejo de imágenes
-----	--------------------

Streamlit	Interfaz gráfica
-----------	------------------

pandas	Manipulación de datos
--------	-----------------------

numpy	Operaciones matemáticas
-------	-------------------------

pdfplumber	Procesamiento PDF
------------	-------------------

PyMuPDF	Lectura avanzada de PDFs
---------	--------------------------

Tecnología	Función
pytest	Testing

6. INSTALACIÓN Y CONFIGURACIÓN

Requisitos Previos

- Python 3.10 o superior
- Tesseract OCR instalado
- Git
- pip

Instalación del Proyecto

Clonar repositorio

```
git clone https://github.com/GuillermoGome2z/Clasificaci-n-y-Extracci-n-de-Documentos-con-OCR-IA.git
```

Entrar a la carpeta

```
cd Clasificaci-n-y-Extracci-n-de-Documentos-con-OCR-IA
```

Crear entorno virtual

```
python -m venv .venv
```

Activar entorno virtual

```
.\venv\Scripts\Activate.ps1
```

Instalar dependencias

```
pip install -r requirements.txt
```

Ejecutar aplicación

```
streamlit run app/app.py
```

7. ESTRUCTURA DEL PROYECTO

```
proyecto/
|
├── app/
├── data/
├── models/
├── notebooks/
├── src/
├── tests/
├── requirements.txt
├── config.py
└── README.md
```

Descripción de Carpetas

Carpeta	Descripción
---------	-------------

app	Interfaz Streamlit
data	Dataset de entrenamiento
models	Modelos entrenados
src	Código fuente
tests	Pruebas automatizadas
notebooks	Análisis y entrenamiento

8. FUNCIONAMIENTO DEL SISTEMA

Paso 1 – Carga de Documento

El usuario carga una imagen o PDF desde la interfaz Streamlit.

Paso 2 – OCR

Tesseract OCR extrae el texto automáticamente.

Paso 3 – Limpieza

El sistema limpia y normaliza el texto.

Paso 4 – Extracción

Se detectan automáticamente:

- NIT
- DPI
- UUID SAT
- Fechas
- Correos
- Montos

Paso 5 – Clasificación

El documento es clasificado automáticamente utilizando IA.

Paso 6 – Resultado

El sistema genera un JSON estructurado.

9. COMPONENTES TÉCNICOS

OCRProcessor

Responsable de procesar imágenes y PDFs utilizando Tesseract OCR.

DataExtractor

Extrae información utilizando expresiones regulares.

SemanticAnalyzer

Analiza contenido semántico y categorías.

ContextualExtractor

Extrae información contextual del documento.

DocumentClassifier

Clasifica documentos utilizando Machine Learning.

OCRPipeline

Coordina todo el flujo de procesamiento.

10. MODELO DE INTELIGENCIA ARTIFICIAL

Modelo Utilizado

El sistema utiliza:

- TF-IDF Vectorizer
- LinearSVC
- CalibratedClassifierCV

Categorías Soportadas

- Factura
- Recibo
- Contrato
- Constancia
- Carta Formal
- Identificación

- Otros

Métricas Alcanzadas

Métrica Resultado

Accuracy 100%

F1 Macro 99.40%

11. FLUJO DE PROCESAMIENTO

Documento



OCR



Limpieza



Extracción



Clasificación IA



JSON



Interfaz

12. ESTRUCTURA DE DATOS

Ejemplo JSON

```
{  
  "documento": "factura.jpg",  
  "categoria": "factura",  
  "nit": "1234567-1",  
  "dpi": "1234 56789 0123",  
  "monto": "Q 1500.00"  
}
```

13. INTERFAZ DEL SISTEMA

La interfaz fue desarrollada utilizando Streamlit con diseño moderno y modo oscuro.

Características:

- Carga de imágenes y PDFs
- Visualización de resultados
- Exportación JSON
- Configuración lateral
- Procesamiento en tiempo real

14. TESTING Y VALIDACIÓN

Framework

Se utilizó pytest para pruebas automatizadas.

Resultados

Tipo	Resultado
------	-----------

Tests ejecutados	158+
------------------	------

Cobertura	Alta
-----------	------

Validación	Correcta
------------	----------

15. SEGURIDAD Y PRIVACIDAD

El sistema fue diseñado considerando privacidad y seguridad.

Características:

- Procesamiento local
- No almacenamiento externo
- Manejo seguro de archivos
- Validación de formatos

16. TROUBLESHOOTING

Error: Tesseract no encontrado

Solución:

```
tesseract --version
```

Configurar PATH correctamente.

Error: numpy no encontrado

Solución:

```
pip install numpy
```

Error: modelo no encontrado

Entrenar nuevamente:

```
python train_classifier.py
```

17. BENEFICIOS DEL SISTEMA

Automatización Inteligente

- Procesamiento automático
- Reducción de tiempo
- Menos errores humanos

Precisión

- Accuracy del 100%
- Alta confiabilidad

Especialización Guatemala

Detecta automáticamente:

- NIT
- DPI
- UUID SAT
- GTQ
- Fechas

Clasificación Automática

Clasifica:

- Facturas
- Recibos
- Contratos
- Constancias
- DPI
- Cartas

OCR Multidioma

- Español
- Inglés

PDFs Multipágina

Procesamiento automático de PDFs complejos.

Seguridad

- Archivos privados
- Sin almacenamiento externo

18. CASOS DE USO

- Digitalización documental
- Facturación electrónica
- Clasificación masiva
- Validación de identidad
- Automatización empresarial
- Cumplimiento SAT Guatemala

19. CONCLUSIONES

El proyecto logró integrar exitosamente OCR e Inteligencia Artificial para automatizar procesos documentales de forma eficiente y precisa.

El sistema permite reducir errores humanos, optimizar tiempos y facilitar la gestión documental mediante clasificación automática y extracción inteligente de datos.

Además, se desarrolló una solución adaptada al contexto guatemalteco, capaz de reconocer documentos fiscales y administrativos utilizados en Guatemala.

Finalmente, el proyecto demuestra el potencial del uso de Inteligencia Artificial aplicada a la automatización documental moderna.

20. REFERENCIAS


- <https://scikit-learn.org/>
- <https://numpy.org/>
- <https://docs.streamlit.io/>
- <https://opencv.org/>
- <https://pandas.pydata.org/>
- <https://github.com/UB-Mannheim/tesseract/wiki>
- <https://pypi.org/project/pytesseract/>

ANEXOS


Capturas Recomendadas

Agregar imágenes de:

- Pantalla principal



- OCR funcionando



- Clasificación

Nombre

demo_carta_formal...

Tamaño

0,00 MB

Tipo

PDF

PROCESAR

Documento ya procesado. Usando resultados guardados.

RESUMEN RÁPIDO

Confianza OCR

Texto digital

Caracteres

1,176

Datos extraídos

9

Tipo doc.

Carta Formal

TEXTO EXTRAÍDO (OCR)

PDF con 1 página(s) · navega entre páginas en la pestaña Resultados.

Selecciona página / factura:

Resumen Interpretado del documento

Carta Formal

DATOS DE LA CARTA

LUGAR

FECHA

22 de abril de 2026

ASUNTO / REFERENCIA

Solicitud formal de servicios de consultoría empresarial

DESTINATARIO

DESTINATARIO

Señor

REMITENTE

REMITENTE / FIRMA

Lic. Roberto Sandoval Fuentes

CARGO DEL FIRMANTE

Director General

CORREO

contacto@empresa.gt

TELÉFONO

2305-6789

CONTENIDO

RESUMEN DEL CUERPO

Estimado señor Director: Por medio de la presente, nos dirigimos a usted respetuosamente para hacer de su conocimiento que

- Resultados JSON

```
resultado_ocr_ia_demo_carta_formal_completo.json X
C: > Users > i7del > Downloads > resultado_ocr_ia_demo_carta_formal_completo.json > {} pages > {} 0 > {} semantic
1 {
2   "original_filename": "demo_carta_formal_completo.pdf",
3   "processed_at": "2026-05-29T18:53:23",
4   "format": "pdf",
5   "status": "success",
6   "total_pages": 1,
7   "pages": [
8     {
9       "page_number": 1,
10      "extraction": {
11        "emails": [
12          "contacto@empresa.gt"
13        ],
14        "phones": [
15          "2305-6789"
16        ],
17        "dates": [
18          "22/04/2026",
19          "01/04/2026",
20          "05/05/2026"
21        ],
22        "urls": [
23          "https://www.empresa.gt"
24        ],
25        "currency": [
26          "Q 25,000.00"
27        ],
28        "nit": [],
29        "dpi": [],
30        "serie_dte": [
31          "CF-2026-0001"
32        ],
33        "serie_sat": [],
34        "autorizacion_sat": [],
35        "autorizacion_sat_ocr": [],
36        "numero_dte": [],
37        "moneda": [],
```

- Procesamiento PDF

